

# Práctica 1:

# Detección de lesiones de la piel con CNNs.



## Visión Artificial

Abril 2024

Grado en Ingeniería Informática

|                         |           |
|-------------------------|-----------|
| Álvaro Ávila Mangas     | 100451125 |
| Marcos Caballero Cortés | 100451047 |
| Pablo Hidalgo Delgado   | 100451225 |

## 1. Solución propuesta

### 1.1 Transformaciones de Datos (data augmentation)

Después de analizar las transformaciones implementadas, hemos decidido descartar la transformación TVRandomBrightness, así como CenterCrop y TVRandomPerspective

La eliminación de TVRandomBrightness se debe a que ajustar el brillo afectaría a los píxeles de la imagen, cambiando su color, lo que podría influir negativamente en la capacidad del modelo para distinguir entre diferentes tipos de melanoma.

Respecto a CenterCrop, hemos optado por utilizar CropByMask en su lugar, ya que esta última transformación nos permite recortar la imagen alrededor del melanoma, proporcionando una región de interés con un pequeño margen adicional.

En cuanto a TVRandomPerspective, no la utilizamos ya que, al realizar la transformación, los bordes de las imágenes quedan en negro, lo cual no es deseable. Además, la variación que introduce en las imágenes no es significativa, especialmente después de aplicar otras transformaciones como Resize, CropByMask y RandomCrop.

Por otro lado, hemos decidido mantener el resto de las transformaciones en nuestro proceso de aumento de datos, ya que cambian la perspectiva o el ángulo de la imagen sin alterar características críticas que podrían influir en la clasificación del tipo de melanoma. Además, al aplicar estas transformaciones con una probabilidad del 50%, aumentamos la diversidad de imágenes disponibles para el entrenamiento (imágenes originales, imágenes a las que solo se le ha aplicado una transformación, varias, todas...), lo que puede mejorar la capacidad del modelo para generalizar.

Con estos ajustes, esperamos obtener un conjunto de datos de entrenamiento más variado y robusto para nuestro modelo de clasificación de melanomas.

Así, las transformaciones que hemos incluido para los datos de entrenamiento son las siguientes:

- TVHorizontalFlip(p=0.5),
- TVRandomRotation(probability=0.5)
- CropByMask(20),
- Rescale(224),
- RandomCrop(224),

### 1.2 Preparación de Datasets y Dataloaders

Se preparan los conjuntos de datos, utilizando las transformaciones para aumentar solo la variedad de los datos de entrenamiento. Sin embargo, para que las imágenes tengan el mismo tamaño y sean compatibles, se realiza CropByMask(20), Rescale(224), RandomCrop(224) también para los conjuntos de validación y test.

### 1.3 Definición del Modelo y entrenamiento

Se define una Red Convolutiva (CNN) para la tarea de clasificación.

La arquitectura diseñada para la CNN es la siguiente:

- Capa Convolutiva 1: 16 filtros, kernel 2x2, stride = 2 → capa de pooling 2x2
- Capa Convolutiva 2: 32 filtros, kernel 3x3, stride = 2 → capa de pooling 2x2
- Capa Convolutiva 3: 64 filtros, kernel 4x4, stride = 2 → capa de pooling 2x2
- Perceptrón Multicapa (fully connected layer):
  - Capa 1 (aplanar salida de Capa Convolutiva 3): neuronas: 256, función de activación: ReLu.
  - Capa 2: neuronas: 50, función de activación: ReLu.
  - Capa de salida: 3 neuronas. Una por cada clase.

Se entrena la red con tasa de aprendizaje de 0.001, función de pérdida crossentropy y el optimizador AdamW.

### 1.4 Evaluación del modelo

Durante el entrenamiento, obtenemos las siguientes métricas: loss de entrenamiento, loss de validación, AUC de melanoma, AUC de queratosis y la media de ambos AUC.

Observando la mejor puntuación para la media de AUC, 0.74, vemos que da un resultado por encima de 0.5, por lo que podemos dar nuestro modelo como válido, ya que supera a un clasificador dummy.

En cuanto a las gráficas, podemos ver que el modelo muestra un descenso rápido y una estabilización temprana en la métrica de loss, lo cual es indicativo de un aprendizaje efectivo en las etapas iniciales. Ocurre lo mismo pero a la inversa para la métrica AUC, donde al inicio se incrementan bastante los valores pero luego se estabilizan.

## 2. Material adicional: tablas, figuras y referencias

Training complete in 21m 6s  
Best model in epoch 9 val AUCs: mel 0.702222 sk 0.777778 avg 0.740000




Figura 1: Gráficas de loss y AUC en train y validation